

AIMS
HDDA

Correction exos cours. — Estimation Non-paramétrique

Histogramme

Soit l'histogramme

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n \sum_{k=1}^D \mathbb{1}_{I_{k,D}}(X_i) \mathbb{1}_{I_{k,D}}(x).$$

- Montrons que $\hat{f}_h(x)$ est une densité de probabilité.
On a

$$\begin{aligned} \int_0^1 \hat{f}_h(x) dx &= \frac{1}{nh} \sum_{i=1}^n \sum_{k=1}^D \mathbb{1}_{I_{k,D}}(X_i) \int_0^1 \mathbb{1}_{I_{k,D}}(x) dx = \frac{1}{nh} \sum_{i=1}^n \sum_{k=1}^D \mathbb{1}_{I_{k,D}}(X_i) \int_{\mathbb{1}_{I_{k,D}}} dx \\ &= \frac{1}{nh} \sum_{i=1}^n \sum_{k=1}^D \mathbb{1}_{I_{k,D}}(X_i) \frac{1}{D} = \frac{1}{n} \sum_{i=1}^n \sum_{k=1}^D \mathbb{1}_{I_{k,D}}(X_i) = 1 \end{aligned}$$

car comme pour tout i , il existe un unique $1 \leq k \leq D$ tel que $X_i \in I_{k,D}$, alors $\sum_{i=1}^n \sum_{k=1}^D \mathbb{1}_{I_{k,D}}(X_i) = n$.

- Montrer pour tout $x \in [0, 1]$, il existe un unique $1 \leq k \leq D$ tel que :

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n \mathbb{1}_{I_{k,D}}(X_i).$$

On a pour tout $x \in [0, 1]$, il existe un unique $1 \leq k \leq D$ tel que $x \in I_{k,D}$ alors $\mathbb{1}_{I_{j,D}}(x) = 0$ pour tout $j \neq k$ et $\mathbb{1}_{I_{k,D}}(x) = 1$, il s'en suit que

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n \sum_{j=1}^D \mathbb{1}_{I_{j,D}}(X_i) \mathbb{1}_{I_{j,D}}(x) = \frac{1}{nh} \sum_{i=1}^n \mathbb{1}_{I_{k,D}}(X_i)$$

Estimateur à noyau de la densité

Soit

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right),$$

l'estimateur à noyau de la densité.

Supposons que :

H1 K est un noyau d'ordre 2.

H2 $\int u^2 |K(u)| du < +\infty$.

H3 f est deux fois continûment différentiable.

Alors :

$$E \left[\hat{f}_n(x) - f(x) \right] \leq C_1(f, K) h^2$$

et

$$\text{Var} \left[\hat{f}_n(x) \right] \leq \frac{C_2(f, K)}{nh}$$

avec $C_1(f, K) := \frac{1}{2} \|f''\|_\infty \int u^2 |K(u)| du$ et $C_2(f, K) := \|f\|_\infty \int K^2(u) du$.

Notons que $\int K = 1$, on a alors

$$\mathbb{E}(\hat{f}_n(x)) - f(x) = \int (f(x - uh) - f(x)) K(u) du.$$

On utilise un développement de Taylor (à l'aide de **H1-H3**) :

$$f(x - uh) = f(x) - f'(x)uh + f''(x) \frac{(uh)^2}{2} + f''(x - \tau uh) \frac{(-uh)^2}{2}$$

avec $0 \leq \tau \leq 1$, on obtient

$$|\mathbb{E}(\hat{f}_n(x)) - f(x)| \leq RC_1(f, K) h^2.$$

Pour la variance posons $K_h = (1/h)K(\cdot/h)$ et notons que

$$\begin{aligned} \text{Var}(\hat{f}_h(x)) &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(K_h(x - X_i)). \\ &\leq \frac{1}{n^2} \sum_{i=1}^n \mathbb{E} [K_h^2(x - X_i)] \\ &= \int \frac{1}{nh^2} f(y) K^2 \left(\frac{x - y}{h} \right) dy \\ &= \int \frac{1}{nh} f(x - uh) K^2(u) du \\ &= \|f\|_\infty \frac{1}{nh} \int K^2(u) du = \frac{C_2(f, K)}{nh} \end{aligned}$$